

DECISION SUPPORT SYSTEM FÜR FUSSBALLTRAINER

Eine CRISP-DM-basierte Analyse der Spielzustände und
Entscheidungsunterstützung beim AFCON 2023 — Nationalmannschaft
Marokko

Datenquelle: StatsBomb Open Data

Wettbewerb: Afrikanischer Nationenpokal 2023 (competition_id=1267)

Analysezeitraum: Januar 2024

Autor	Hamza Nour
Betreuer	—
Datum	Juni 2024
Sprache	Deutsch
Seitenanzahl	ca. 20 Seiten

Zusammenfassung (Abstract)

Zielsetzung: Diese Arbeit präsentiert ein datengetriebenes, präskriptives Entscheidungsunterstützungssystem (Decision Support System, DSS) für Fußballtrainer zur In-Game-Entscheidungsfindung. Das System analysiert Echtzeit-Spielzustände und empfiehlt dem Trainer optimale Interventionen (Einwechslungen, Formationswechsel, Pressing-Intensitätsanpassungen), ohne auf hartcodierte Regeln zu setzen.

Methodik: Als Rahmenwerk wird das CRISP-DM-Modell (Cross-Industry Standard Process for Data Mining) angewendet. Die Datenbasis bildet das StatsBomb Open Data Repository, konkret die vier Spiele der marokkanischen Nationalmannschaft beim Afrikanischen Nationenpokal 2023 (AFCON 2023). Aus 12.575 Rohereignissen wurden 51 rollierende Feature-Vektoren je Spielminute extrahiert.

Modellierung: Ein zweistufiges Pipeline-Modell wurde entwickelt: (1) Ein K-Means-Clustering-Algorithmus klassifiziert den aktuellen Spielzustand in vier semantische Cluster (Dominierend, Unter Druck, Aufholjagd, Ausgeglichen). (2) Ein Random-Forest-Klassifikator prognostiziert, ob eine Intervention den xG-Differenz-Wert verbessert.

Ergebnisse: Das System erreicht einen LOMO-AUC von 0,71 und einen präskriptiven Lift von +0,57 xG-Differenz-Einheiten, wenn den Modellempfehlungen gefolgt wird. Der Dominant_Efficient-Cluster tritt in gewonnenen Spielen zu 28 % der Spielzeit auf, verglichen mit 18 % in unentschiedenen und verlorenen Spielen.

Schlussfolgerung: Das Prototyp-System liefert datengetriebene, taktisch sinnvolle Empfehlungen. Für den produktiven Einsatz wird eine Erweiterung der Trainingsdaten auf alle 52 AFCON-2023-Spiele empfohlen.

Schlüsselwörter: CRISP-DM · StatsBomb · Decision Support System · K-Means · Random Forest · xG · AFCON 2023 · Fußballanalytik · Marokko

Inhaltsverzeichnis

1	Einleitung und Business Understanding	4
2	Datenverstehen (Data Understanding)	5
2.1	Datenquelle und Spielübersicht	5
2.2	Ereignistypen und Datenstruktur	6
2.3	Offensivanalyse: Schüsse und Expected Goals (xG)	6
2.4	Passanalyse und Spielaufbau	7
2.5	Pressing und Defensivverhalten	7
2.6	Temporale Dynamik	8
3	Datenvorbereitung (Data Preparation)	9
3.1	Feature-Engineering-Pipeline	9
3.2	Rollierende Spielzustand-Vektoren	10
3.3	Interventionslabeling und Outcome-Signal	10
4	Modellierung (Modelling)	12
4.1	Stufe A: Spielzustand-Clustering (K-Means)	12
4.2	Stufe B: Interventions-Prädiktor (Random Forest)	13
4.3	Cluster-Empfehlungsprofile	14
5	Evaluation	15
5.1	Cluster-Qualität	15
5.2	Klassifikator-Güte	15
5.3	Präskriptiver Mehrwert	16
5.4	Business-KPI-Ausrichtung	16
6	Systemarchitektur und Deployment (Streamlit)	17
7	Diskussion, Limitierungen und Ausblick	18
8	Schlussfolgerung	19
	Literaturverzeichnis	20
	Anhang: Glossar und Abbildungsverzeichnis	20

1. Einleitung und Business Understanding

Fußballtrainer stehen während eines Spiels unter enormem Entscheidungsdruck. Innerhalb von Sekunden müssen sie komplexe taktische Entscheidungen treffen — etwa wann und wen einzuwechseln, ob die Formation angepasst werden sollte oder ob das Pressing erhöht werden muss. Diese Entscheidungen basieren traditionell auf Erfahrung, Intuition und visueller Beobachtung. Moderne Datenanalysemethoden bieten die Möglichkeit, diese Entscheidungsprozesse durch quantitative Signale zu unterstützen und zu objektivieren.

Das Ziel dieser Arbeit ist die Entwicklung eines **präskriptiven, datengetriebenen Entscheidungsunterstützungssystems (DSS)** für In-Game-Coaching. Im Gegensatz zu deskriptiven Systemen, die nur Spielstatistiken anzeigen, oder prädiktiven Systemen, die zukünftige Ereignisse vorhersagen, liefert ein präskriptives System konkrete Handlungsempfehlungen.

1.1 Geschäftsziele (Business Goals)

- Identifikation des optimalen Zeitpunkts für Spielerwechsel basierend auf rollierenden Spielzustandsmetriken
- Erkennung taktisch kritischer Spielphasen und Empfehlung von Formationsanpassungen
- Bereitstellung eines interpretierbaren, in Echtzeit nutzbaren Dashboard-Prototyps (Streamlit)
- Vollständig datengetrieben — keine hardcodierten Fußball-Regeln

1.2 CRISP-DM als Rahmenwerk

Als methodisches Rahmenwerk wird das **CRISP-DM-Modell** (Cross-Industry Standard Process for Data Mining) eingesetzt. Abbildung 1 visualisiert den iterativen Prozess mit seinen sechs Phasen. Der Übergang von der Datenaufbereitung zur Modellierung ist in diesem Projekt besonders eng verzahnt, da die Feature-Engineering-Pipeline direkt auf die Anforderungen des Clustering-Modells ausgerichtet wurde.

Abbildung 1: CRISP-DM Prozessmodell (Cross-Industry Standard Process for Data Mining)




Abbildung 1: CRISP-DM Prozessmodell — iterativer Ablauf der sechs Phasen (Business Understanding → Data Understanding → Data Preparation → Modellierung → Evaluation → Deployment)

2. Datenverstehen (Data Understanding)

2.1 Datenquelle und Spielübersicht

Die Datenbasis bildet das **StatsBomb Open Data Repository** — eine der umfangreichsten öffentlich zugänglichen Fußball-Ereignisdatenbanken. StatsBomb erfasst alle Spielereignisse (Events) mit xy-Koordinaten, Zeitstempel, Spieler- und Teaminformationen sowie ereignisspezifischen Attributen.

Für diese Analyse wurden die vier Spiele der **marokkanischen Nationalmannschaft** beim **Afrikanischen Nationenpokal 2023** (AFCON 2023, competition_id=1267, season_id=107) ausgewählt:

Spiel-ID	Datum	Heimteam	Ergebnis	Auswärtsteam	Phase
3920394	17.01.2024	Marokko	3:0	Tansania	Gruppenphase
3920405	21.01.2024	Marokko	1:1	Kongo DR	Gruppenphase
3920419	24.01.2024	Sambia	0:1	Marokko	Gruppenphase
3922243	30.01.2024	Marokko	0:2	Südafrika	Runde der 16

Abbildung 2: Spielübersicht — Marokko bei AFCON 2023




Abbildung 2: Spielübersicht Marokko AFCON 2023 — Ergebnisse, Schussanzahl, xG-Werte und Pressing-Häufigkeit je Spiel

2.2 Ereignistypen und Datenstruktur

Insgesamt wurden **12.575 Ereignisse** aus vier Spielen geladen. Davon entfallen **6.736 Ereignisse** auf die marokkanische Mannschaft. Die Ereignisdaten umfassen 29 verschiedene Typen:

Ereignistyp	Anzahl (MAR)	Anteil
Pass	1.945	28,9 %
Ball Receipt	~1.900	28,2 %
Carry	~780	11,6 %
Pressure	496	7,4 %
Ball Recovery	~350	5,2 %
Schuss (Shot)	58	0,9 %
Dribbling	55	0,8 %
Einwechslung	19	0,3 %
Sonstige	~1.133	16,8 %

Datenqualität: Die Datensätze sind sehr vollständig. Fehlende Werte treten nur bei ereignisspezifischen Feldern auf (z.B. shot_statsbomb_xg bei Nicht-Schuss-Ereignissen, 99,1 % Nullanteil — erwartungsgemäß). Die Koordinaten (location) fehlen in nur 1,1 % der Fälle. Minuteninformationen sind zu 100 % vorhanden.

2.3 Offensivanalyse: Schüsse und Expected Goals (xG)

Marokko erzielte in vier Spielen insgesamt **58 Schüsse** mit einem kumulativen **xG-Wert von 7,87** und **5 Toren** (xG/Tor-Verhältnis 1,57). Der durchschnittliche xG-Wert pro Schuss beträgt 0,136, was auf überwiegend zentralen und qualitativ hochwertigen Abschlüssen hinweist.

Spiel	Schüsse	Tore	xG	xG/Schuss	Passquote
vs. Tansania	15	3	2,30	0,153	86,9 %
vs. Kongo DR	11	1	1,06	0,096	82,0 %
vs. Sambia	19	1	2,42	0,127	87,5 %
vs. Südafrika	13	0	2,09	0,161	84,0 %
Gesamt	58	5	7,87	0,136	85,3 %

Abbildung 3: Schussverteilung Marokko — AFCON 2023 (alle 4 Spiele)
Größe der Punkte = xG-Wert, Blickrichtung: Marokko greift nach rechts an




Abbildung 3: Schussverteilung Marokko AFCON 2023 — 79 % der Schüsse aus der zentralen Angriffszone (att_center).
Rot = Tor, Orange = Gehalten, Grau = Verpasst/Geblockt. Punktgröße = xG




Abbildung 4: xG- und Schussverteilung nach 15-Minuten-Abschnitten — Marokko ist in der Schlussphase (75-90 min, 90+) besonders gefährlich

2.4 Passanalyse und Spielaufbau

Mit **1.945 Pässen** und einer Gesamtpassquote von **85,3 %** zeigt Marokko ein ballbesitzorientiertes Spielsystem. Bemerkenswert ist der Abfall der Passquote unter Druck auf **75,6 %** — ein Indikator für nachlassende technische Qualität in Stresssituationen. 639 progressive Pässe (>10 m Raumgewinn in Spielrichtung) unterstreichen den vertikalen Spielstil.

- **639** progressive Pässe (33 % aller Pässe) — hohe Direktheit
- **55** Flanken — hauptsächlich in der Schlussphase (vs. Südafrika: 20)
- **70** Seitenverlagerungen — taktisches Mittel zur Raumschaffung
- **45** torschussvorbereitende Pässe (Key Passes)
- **3** direkte Torvorlagen (Assists)




Abbildung 5: Passquote nach Spielzone — Passquote sinkt deutlich in der Angriffszone (att_center: 66,7 %). Zahlen geben Anzahl Pässe pro Zone an.

2.5 Pressing und Defensivverhalten

Marokko führte **496 Pressings** durch — durchschnittlich 124 pro Spiel. Die Pressing-Intensität ist nicht gleichmäßig verteilt, sondern zeigt eine klare **Spitze im 45–60-Minuten-Fenster** (132 Pressings), was auf ein intensives Pressing direkt nach der Halbzeit hindeutet — möglicherweise als taktische Anweisung des Trainers.




Abbildung 6: Pressing-Intensität nach Zone und Spielabschnitt — 45-60 min zeigt die höchste Pressing-Aktivität, besonders im Mittelfeld

2.6 Temporale Dynamik und Schlüsselbefunde

Die zeitliche Analyse über 15-Minuten-Fenster liefert wichtige Muster, die als Features für das Modell dienen:

- **xG-Rate:** Höchste Werte in 30-45, 45-60, 75-90 und 90+ min
- **Passquote:** Sinkt von 91,4 % (15-30 min) auf 77,3 % (75-90 min) — Müdigkeitssignal
- **Pressing:** Stark in 45-60 min (120 Pressings), schwächer in 30-45 min (44)
- **Einwechslungen:** 19 Wechsel in 4 Spielen, überwiegend zwischen Minute 62-83

3. Datenvorbereitung (Data Preparation)

Die Datenvorbereitung transformiert die rohen Ereignisdaten in strukturierte, modellierbare Feature-Vektoren. Abbildung 7 zeigt die gesamte Pipeline.

Abbildung 7: Feature-Engineering-Pipeline — Von Rohdaten zum Game-State-Vektor




Abbildung 7: Feature-Engineering-Pipeline — Fünf Stufen von Rohdaten bis zum 18-dimensionalen Game-State-Vektor

3.1 Atomare Feature-Extraktion

In der ersten Stufe werden aus jedem Ereignis binäre oder numerische Merkmale extrahiert. Die vollständige Liste umfasst 22 atomare Features:

Feature	Beschreibung	Typ
is_shot	Ereignis ist ein Schuss	binär
is_goal	Schuss mit Ergebnis Tor	binär
xg	StatsBomb xG-Wert (0 wenn kein Schuss)	float
is_pass / pass_completed	Pass und ob erfolgreich	binär
pass_under_pressure	Pass unter gegnerischem Druck	binär
is_progressive_pass	Pass mit >10m x-Raumgewinn	binär
is_key_pass	Torschussvorbereitender Pass	binär
is_pressure	Pressing-Aktion	binär
loc_x / loc_y	Ereigniskordinaten (StatsBomb-Pitch)	float

3.2 Rollierende Spielzustand-Vektoren

Die atomaren Features werden über ein **gleitendes 15-Minuten-Fenster** aggregiert, um für jede Spielminute einen Spielzustand-Vektor zu erzeugen. Dies liefert **400 Zeilen × 51 Features** (alle 4 Spiele zusammen). Der Fenstergröße von 15 Minuten wurde gewählt, da sie einem Spielabschnitt entspricht und ausreichend Ereignisse für stabile Schätzungen enthält.

Drei besonders wichtige zusammengesetzte Features:

- **momentum_index** = $2 \cdot \text{mar_xg_rate} + \text{mar_progressive_pass_rate} + 0,5 \cdot \text{mar_pressure_intensity} - 2 \cdot \text{opp_xg_rate} - 0,5 \cdot \text{opp_pressure_intensity}$

- **xg_diff** = rolling_xg_MAR – rolling_xg_GEG (Maß für die Spielüberlegenheit)
- **pass_completion_delta** = aktuelle_Passquote – Passquote(0–30 min) (Müdigkeitsindikator)




Abbildung 8: Temporale Dynamik der Rolling-Features — vs. Tansania (3:0). Oben: xG-Rate (Marokko grün / Gegner rot), Mitte: Passquote, Unten: Spielzustand-Cluster. Vertikale Linien = Einwechslungen

3.3 Interventionslabeling und Outcome-Signal

Für das Training des Interventions-Prädiktors werden alle **21 Interventionen** (19 Einwechslungen + 2 Formationswechsel) mit ihrem Kontext und Ergebnis gelabelt.

Outcome-Signal: Das Vorzeichen der Veränderung der xG-Differenz im 15-Minuten-Fenster nach der Intervention im Vergleich zum 15-Minuten-Fenster davor bestimmt das Klassenlabel:

```
outcome_positive = 1 wenn post_xg_diff - pre_xg_diff > 0
```

Von 21 Interventionen führten **11 (52 %) zu einer Verbesserung** der xG-Differenz. Das Datensatz ist nahezu ausbalanciert, was die Klassifikation erleichtert. Formationswechsel zeigten in beiden Fällen (100 %) positive Ergebnisse; Einwechslungen nur in 47 % der Fälle.

4. Modellierung (Modelling)

Die Modellierung folgt einem **zweistufigen Pipeline-Ansatz**: Zunächst klassifiziert ein unüberwachtes Clustering-Modell den aktuellen Spielzustand, anschließend trifft ein überwachtes Klassifikationsmodell eine binäre Interventionsempfehlung.

4.1 Stufe A: Spielzustand-Clustering (K-Means)

K-Means-Clustering mit K=4 wurde auf 18 normalisierten (StandardScaler) Spielzustand-Features angewendet. Die Wahl K=4 basiert auf dem **Elbow-Kriterium** und der taktischen Interpretierbarkeit: vier Cluster entsprechen intuitiven Spielphasen im Fußball.

Die vier Cluster wurden post-hoc anhand ihrer Feature-Mittelwerte semantisch benannt — ohne Nutzung von Fußball-Domänenwissen als Schwellenwert:

Cluster	Beschreibung	n (Min.)	Anteil
Dominant_Efficient (C1)	Hohe MAR xG-Rate, territoriale Überlegenheit, pos. Score	93	23,2 %
Balanced_Phase (C3)	Ausgeglichene KPIs, mittlerer Momentum, knappe Führung	127	31,8 %
Chasing_Game (C2)	Niedrige Tordifferenz, niedriger Momentum-Index	150	37,5 %
Pressing_Under_Threat (C0)	Hohe GEG xG-Rate, territoriale Unterlegenheit, gefährlich	30	7,5 %




Abbildung 9: PCA-Projektion der K-Means-Cluster auf 2 Hauptkomponenten (erklärte Varianz: 48,2 %). Jeder Punkt entspricht einer Spielminute.



Abbildung 10: Cluster-Profil-Heatmap — Normalisierte Feature-Mittelwerte je Cluster. Grün = hoher Wert, Rot = niedriger Wert relativ zum Maximum.

4.2 Stufe B: Interventions-Prädiktor (Random Forest)

Ein **RandomForestClassifier** (`n_estimators=200`, `max_depth=4`, `class_weight='balanced'`) wurde auf den 12 Interventions-Features trainiert und mittels **Leave-One-Match-Out Cross-Validation (LOMO-CV)** evaluiert. LOMO-CV ist bei nur 4 Spielen die einzig datenleck-freie CV-Strategie, da Daten desselben Spiels zeitlich korreliert sind.

Zusätzlich wurde ein **DecisionTreeClassifier** (`max_depth=3`) trainiert, um für den Coach nachvollziehbare, regelbasierte Empfehlungen zu generieren. Die Entscheidungsregel des Baums lautet vereinfacht:

WENN `mar_xg_rate` normal (nicht abgefallen) **UND** `opp_xg_rate` niedrig
→ DANN Intervention führt wahrscheinlich zu Verbesserung (`outcome_positive = 1`)




Abbildung 11: Feature-Wichtigkeit des Random-Forest-Klassifikators. xG-Differenz (23,1 %), Momentum-Index (17,8 %) und MAR xG-Rate (15,1 %) dominieren die Vorhersage.

4.3 Cluster-bedingte Empfehlungsprofile

Durch die Verknüpfung von Cluster-Labels und Interventionsergebnissen entstehen cluster-spezifische Empfehlungsprofile. Diese bilden die Wissensbasis des DSS:

Spielzustand	Intervention	Positiv-Rate	Ø Minute	Ø Score-Diff
Dominant_Efficient	Einwechslung	100 %	72. Min	+1,8
Dominant_Efficient	Formationswechsel	100 %	81. Min	+3,0
Chasing_Game	Einwechslung	100 %	68. Min	-1,0
Chasing_Game	Formationswechsel	100 %	69. Min	-1,0
Balanced_Phase	Einwechslung	27 %	67. Min	+0,6
Pressing_Under_Threat	Einwechslung	0 %	79. Min	±0

Interpretation: Im Cluster 'Pressing_Under_Threat' (unter Druck) führen späte Einwechslungen (Minute 79) zu keiner xG-Verbesserung — möglicherweise ist eine frühere oder strukturellere Maßnahme (Formationswechsel) sinnvoller.

Abbildung 12: Interventionsergebnisse — xG-Differenz-Veränderung nach Einwechslungen & Formationswechseln




Abbildung 12: Interventionsergebnisse — Links: xG-Differenz vor vs. nach Intervention (Punkte über der Diagonalen = Verbesserung). Rechts: Positiv/Negativ-Bilanz je Spielzustand-Cluster.

5. Evaluation

5.1 Cluster-Qualität

Die Cluster-Qualität wird mit drei komplementären Metriken bewertet:

Metrik	Wert	Interpretation
Silhouette Score	0,198	Moderate Trennung — erwartet bei überlappenden Spielphasen
Calinski-Harabasz	81,46	Gutes Verhältnis Zwischen- zu Innercluster-Varianz
Davies-Bouldin Index	1,621	Akzeptabel; niedrigerer Wert wäre besser (Ziel: <1,5)
KMeans Inertia	4452,4	Benchmark für Vergleich mit mehr Trainingsdaten

Der moderate Silhouette Score von 0,198 ist bei Fußball-Spielzustand-Daten realistisch, da die Übergänge zwischen Spielphasen fließend sind. Der Sweep über K=2 bis K=6 zeigt, dass K=4 einen sinnvollen Kompromiss zwischen Güte und Interpretierbarkeit darstellt.

5.2 Klassifikator-Güte (LOMO-CV)

Metrik	Wert	Hinweis
LOMO AUC	0,71	Über Zufallsniveau (0,5); Varianz ±0,30 wegen kleiner Stichprobe
Average Precision	0,75	Gutes Verhältnis Precision/Recall
Brier Score	0,234	Unter Basisrate (0,249) — kalibrierte Wahrscheinlichkeiten
Accuracy (LOMO)	76 %	10/10 richtig klassifizierte Negativ, 8/11 Positiv

5.3 Präskriptiver Mehrwert

Der entscheidende Qualitätsindikator für ein präskriptives System ist der **Lift**: Verbessern sich die xG-Differenz-Werte mehr, wenn das Modell zur Intervention rät, als wenn es zu Zurückhaltung rät?

Szenario	Ø ΔxG-Diff	n
Modell empfiehlt Intervention	+0,331	11
Modell empfiehlt Abwarten	−0,239	10
Prescriptive Lift (Differenz)	+0,569	—

Ein Lift von **+0,569 xG-Differenz-Einheiten** bedeutet: Wenn Marokko interveniert, wenn das Modell es empfiehlt, verbessert sich die xG-Situation um durchschnittlich 0,33 xG-Einheiten. Bei Nichtbefolgen verschlechtert sie sich um 0,24. Dies bestätigt den präskriptiven Mehrwert des Systems.

5.4 Business-KPI-Ausrichtung

Der Dominant_Efficient-Cluster tritt zu **28,2 % der Spielzeit in Siegen** auf, verglichen mit **18,4 % in Unentschieden und Niederlagen**. Dies validiert, dass der Cluster taktisch bedeutsam und mit Spielerfolg korreliert ist.

Abbildung 15: Evaluations-Metriken — Cluster-Qualität, Klassifikator-Güte und Präskriptiver Mehrwert




Abbildung 15: Evaluations-Überblick — Links: Silhouette-Score nach K, Mitte: LOMO-AUC pro Testspiel, Rechts: Präskriptiver Lift (Δ xG-Differenz)

6. Systemarchitektur und Deployment (Streamlit)

Der sechste CRISP-DM-Schritt — das Deployment — wird durch einen interaktiven **Streamlit-Prototyp** realisiert. Das System ist als Web-App konzipiert, die ein Live-Spiel simuliert und dem Trainer in Echtzeit Empfehlungen anzeigt.

Abbildung 14: Systemarchitektur des Prescriptive Decision Support Systems




Abbildung 14: Systemarchitektur des präskriptiven DSS — Von StatsBomb-Rohdaten über Feature-Extraktion und Modelle bis zur Streamlit-Coach-Oberfläche

6.1 Dashboard-Komponenten

- **Live-Spieluhr:** Simulation des Spielverlaufs mit Minutensteuerung
- **KPI-Gauges:** Echtzeit-Anzeige von xG-Rate, Passquote, Momentum-Index, Pressing-Intensität
- **Spielzustand-Badge:** Aktueller Cluster-Label mit Farbcodierung (Grün/Gelb/Rot)
- **Empfehlungskarte:** 'Einwechslung empfohlen' / 'Formationswechsel erwägen' mit Konfidenzwert
- **Spielerranking:** Rangliste der Spieler nach Leistungsindikatoren im aktuellen 15-Min-Fenster
- **PCA-Clustermap:** Visualisierung der Spielzustand-Trajektorie im PCA-Raum
- **Temporale KPI-Grafiken:** Verlauf von xG, Passquote und Pressing über die Spielzeit

6.2 Spieler-Performance-Analyse

Die Player-Snapshot-Daten ermöglichen eine spieterspezifische Leistungsanalyse zum Zeitpunkt der Intervention. Abbildung 13 zeigt die Radar-Charts der sechs Schlüsselspieler Marokkos.

Abbildung 13: Spieler-Performance-Radar — Top-6-Spieler Marokko AFCON 2023
(Werte normalisiert; höher = besser relativ zur Gruppe)




Abbildung 13: Spieler-Performance-Radar — Normalisierte Leistungsmetriken für die 6 wichtigsten Spieler Marokkos (xG, Pässe, Passquote, Schlüsselpässe, Dribbling-Erfolg, Pressings)

7. Diskussion, Limitierungen und Ausblick

7.1 Stärken des Ansatzes

- **Vollständig datengetrieben:** Keine hardcodierten Fußball-Regeln — alle Schwellenwerte werden aus den Daten gelernt
- **Interpretierbarkeit:** DecisionTree liefert nachvollziehbare Entscheidungsregeln; Feature Importances erklärbar
- **Zweistufig:** Trennung von Situationserkennung (Clustering) und Aktionsempfehlung (RF) ermöglicht modulare Erweiterung
- **Korrekte Evaluation:** LOMO-CV verhindert Datenleckage über Spielgrenzen
- **Präskriptiver Lift validiert:** +0,57 xG-Diff-Einheiten bei Befolgung der Empfehlungen

7.2 Limitierungen

Kategorie	Limitierung	Empfehlung
Daten	Nur 4 Spiele (n=21 Interventionen) — sehr kleine Stichprobe	Alle 52 AFCON-2023-Spiele nutzen
Daten	Kein Erschöpfungs- oder Verletzungsdatum verfügbar	Minuten-gespielt als Proxy erweitern
Daten	Gegner-Taktik nur partiell beobachtbar	Lineup-Qualitäts-Feature ergänzen
Modell	Silhouette-Score 0,20 (schwache Trennung)	DBSCAN oder GMM auf größerem Datensatz testen
Modell	LOMO AUC $\pm 0,30$ Standardabweichung — hohe Varianz	≥ 50 Interventionen für robuste CV benötigt
Modell	Kein Spieler-Empfehlungs-Ranking implementiert	Ranking-Modell auf Snapshot-Daten trainieren
Deployment	Keine Echtzeit-API — bisher nur Simulation	StatsBomb Live-API oder Opta-Feed integrieren

7.3 Ausblick

Für die Weiterentwicklung des Systems werden folgende Schritte empfohlen:

- (1) **Datenerweiterung:** Training auf allen 52 AFCON-2023-Spielen und weiteren StatsBomb-Wettbewerben (Premier League, Champions League) für einen robusten, verallgemeinerbaren Interventions-Prädiktor
- (2) **Spieler-Recommenderr:** Ergänzung eines Ranking-Modells auf Basis der Player-Snapshot-Daten für konkrete 'Wer soll eingewechselt werden?'-Empfehlungen
- (3) **Gegner-Modellierung:** Integration gegnerischer Taktik-Features (Gegner-Cluster, Formationsmuster) für kontext-sensitivere Empfehlungen
- (4) **Reinforcement Learning:** Langfristig ein RL-basierter Agent, der die gesamte Spielsequenz optimiert (Reward = Torergebnis, nicht nur xG-Differenz)
- (5) **Live-Integration:** Anbindung an eine Echtzeit-Event-API für den tatsächlichen Spieltageinsatz

8. Schlussfolgerung

Diese Arbeit demonstriert die Machbarkeit eines vollständig datengetriebenen, präskriptiven Entscheidungsunterstützungssystems für In-Game-Coaching im Fußball auf Basis des CRISP-DM-Rahmenwerks und StatsBomb Open Data.

Die Analyse der vier AFCON-2023-Spiele Marokkos ergibt ein klares Bild: Marokko ist ein ballbesitzstarkes, vertikal spielendes Team mit einer Stärke in der Schlussphase (hohe xG-Rate ab Minute 75). Die Passqualität sinkt unter Druck und gegen Spielende — ein messbares Müdigkeitssignal. Formationswechsel führten in beiden dokumentierten Fällen zu einer Verbesserung der xG-Situation, während Einwechslungen einen positiveren Effekt zeigten, wenn sie im Cluster 'Dominant_Efficient' oder 'Chasing_Game' stattfanden.

Zusammenfassung der Kernergebnisse:

- 58 Schüsse | 7,87 xG | 85,3 % Passquote | 496 Pressings
- K-Means K=4 Silhouette: 0,198 | Random Forest LOMO-AUC: 0,71
- Präskriptiver Lift: **+0,57 xG-Differenz-Einheiten**
- Dominant_Efficient-Cluster: 28 % in Siegen vs. 18 % in anderen Spielen
- 21 gelabelte Interventionen | 52 % positive Outcomes

Das System ist bereit für den nächsten Schritt: Die Implementierung des Streamlit-Prototyps als interaktives Coach-Dashboard, das Trainern während des Spiels in Echtzeit datengetriebene Entscheidungshilfe bietet — transparent, erklärbar und ohne Hardcoding von Fußball-Regeln.

Literaturverzeichnis

- [1] Chapman, P. et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc. URL: <https://www.crisp-dm.org/>
- [2] StatsBomb (2024). *StatsBomb Open Data Repository*. GitHub. URL: <https://github.com/statsbomb/open-data>
- [3] StatsBomb (2022). *StatsBomb Event Data Specification v3.0*. StatsBomb Ltd., London.
- [4] Gudmundsson, J. & Horton, M. (2017). Spatio-Temporal Analysis of Team Sports. *ACM Computing Surveys*, 50(2), 1–34.
- [5] Rein, R. & Memmert, D. (2016). Big data and tactical analysis in elite soccer. *SpringerPlus*, 5(1), 1410.
- [6] Fernandez, J. et al. (2019). Decomposing the Immeasurable Sport: A deep learning expected possession value framework for soccer. *MIT Sloan Sports Analytics Conference*.
- [7] Decroos, T. et al. (2019). Actions Speak Louder than Goals: Valuing Player Actions in Football. *KDD 2019*, 1851–1861.
- [8] Pappalardo, L. et al. (2019). A public data set of spatio-temporal match events in soccer leagues. *Scientific Data*, 6(1), 236.
- [9] Breiman, L. (2001). Random Forests. *Machine Learning*, 45, 5–32.
- [10] Rousseeuw, P.J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.
- [11] Beal, R. et al. (2019). Artificial Intelligence for Team Sports: A Survey. *The Knowledge Engineering Review*, 34, e28.
- [12] Power, P. et al. (2017). Not All Passes Are Created Equal: Objectively Measuring the Risk and Reward of Passes in Soccer. *KDD 2017*, 1605–1613.
- [13] Scikit-learn developers (2024). *scikit-learn: Machine Learning in Python*. URL: <https://scikit-learn.org/>
- [14] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825–2830.
- [15] StreamlitInc. (2024). *Streamlit — The fastest way to build data apps*. URL: <https://streamlit.io/>

Anhang: Glossar und Abbildungsverzeichnis

A.1 Glossar

xG (Expected Goals)	Statistisches Maß für die Wahrscheinlichkeit, dass ein Schuss zu einem Tor führt (0–1).
CRISP-DM	Cross-Industry Standard Process for Data Mining — iterativer 6-Phasen-Prozess für Data-Mining-Projekte.
StatsBomb Open Data	Öffentlich zugängliche Fußball-Ereignisdatenbank mit detaillierten xy-kooordinierten Event-Daten.
K-Means	Unüberwachter Clustering-Algorithmus, der n Datenpunkte in K Cluster partitioniert.
Random Forest	Ensemble-Lernmethode aus Entscheidungsbäumen mit Mehrheitsvotum.
LOMO-CV	Leave-One-Match-Out Cross-Validation — CV-Strategie, bei der je ein Spiel als Testdaten dient.
Rolling Window	Gleitendes Zeitfenster für die Berechnung rollierender Statistiken (hier: 15 Minuten).
Momentum Index	Komposit-Feature: $2 \cdot \text{mar_xg_rate} + \text{mar_prog_pass_rate} + 0,5 \cdot \text{mar_pressure} - 2 \cdot \text{opp_xg_rate} - 0,5 \cdot \text{opp_pressure}$.
PCA	Principal Component Analysis — Dimensionsreduktionsverfahren zur Visualisierung hochdimensionaler Daten.
DSS	Decision Support System — System zur Unterstützung menschlicher Entscheidungsprozesse.
Prescriptive Analytics	Analytikform, die konkrete Handlungsempfehlungen generiert (über deskriptiv und prädiktiv hinaus).
AFCON	Africa Cup of Nations — Afrikanischer Fußball-Nationenpokal, 2023 ausgetragen im Januar 2024 in der Elfenbeinküste.

A.2 Abbildungsverzeichnis

- Abbildung 1: CRISP-DM Prozessmodell
- Abbildung 2: Spielübersicht Marokko AFCON 2023
- Abbildung 3: Schussverteilung (Shot Map)
- Abbildung 4: xG- und Schussverteilung nach Spielabschnitt
- Abbildung 5: Passquote nach Spielzone
- Abbildung 6: Pressing-Intensität nach Zone und Spielabschnitt (Heatmap)
- Abbildung 7: Feature-Engineering-Pipeline
- Abbildung 8: Temporale Dynamik der Rolling-Features
- Abbildung 9: PCA-Projektion der K-Means-Cluster
- Abbildung 10: Cluster-Profil-Heatmap
- Abbildung 11: Feature-Wichtigkeit des Random-Forest-Klassifikators
- Abbildung 12: Interventionsergebnisse (vor/nach xG-Differenz)

Abbildung 13: Spieler-Performance-Radar

Abbildung 14: Systemarchitektur des präskriptiven DSS

Abbildung 15: Evaluations-Metriken Übersicht